

Uniwersytet Ekonomiczny w Katowicach

Kierunek: Informatyka

Studia niestacjonarne II stopnia

Laboratorium ETL

Rok akademicki 2025/2026

Budowa procesów ETL w SAS Data Integration Studio

Autor: Szymon Zackiewicz

Spis treści

1.	Analiza koncepcji ELT oraz jezior danych	4
	Literatura	9
2.	Cel realizacji projektu	10
3.	Opis źródeł danych	10
4.	Ocena jakości danych	14
	Jednoznaczność klucza	15
	Kompletność danych	16
	Poprawność wartości słownikowych	16
	Poprawność formatu danych	17
5.	Opis procesów ETL	18
	Proces 1 – Schemat gwiazdy	18
	Customer_dim	19
	Product_dim	21
	SpecialOffer_dim	22
	Time_dim	23
	Sales_fact	25
	Analiza danych wynikowych	27
	Proces 2 – Źródła zewnętrzne, walidacja danych	28
	Źródło zewnętrzne danych	28
	Mapowanie danych JSON do tabeli SAS	29
	Symulacja błędnych danych w zamówieniach	30
	Walidacja danych i identyfikacja błędów	31
	Obliczenie dystansu Levenshteina i korekta danych	32
	Budowa tabeli wynikowej	34
	Tabela docelowa	34
	Analiza danych wynikowych	35
	Proces 3 – Analiza kosztu dostawy	36
	Selekcja i przygotowanie danych	36
	Tabela docelowa	37
	Kolumny wyliczane	37
	Analiza danych wynikowych	38
	Proces 4 – Opóźnienia dostaw, klucz zastępczy	39

Struktura tabeli docelowej DeliveryDelayFact.....	39
Logika wyznaczania opóźnień.....	40
Uwagi dotyczące danych źródłowych	40
Dodanie klucza zastępczego (Surrogate Key).....	41
Analiza danych wynikowych.....	42
Proces 5 – Uszkodzone detale	43
Źródła danych.....	43
Tabela docelowa.....	44
Kolumny wyliczane	45
Analiza danych wynikowych.....	46
6. Przykładowe raporty	47
Raporty sprzedażowe – schemat gwiazdy	47
Raporty jakości danych – źródła zewnętrzne i walidacja danych.....	47
Raporty logistyczne – koszty przesylek.....	48
Raporty jakości logistyki – opóźnienia dostaw.....	48
Raporty produkcyjne – analiza uszkodzonych detali.....	49
7. Podsumowanie.....	49

1. Analiza koncepcji ELT oraz jezior danych

1. Wprowadzenie

Współczesne systemy analityczne muszą radzić sobie z rosnącą ilością danych, ich różnorodnością oraz wysoką dynamiką zmian. Tradycyjne podejścia do integracji danych, oparte na hurtowniach danych i procesach ETL (Extract, Transform, Load), coraz częściej okazują się niewystarczające w kontekście danych niestrukturalnych, półstrukturalnych oraz dużej skali przetwarzania. Odpowiedzią na te wyzwania są nowe koncepcje architektoniczne, takie jak ELT (Extract, Load, Transform) oraz jeziora danych (Data Lakes).

Celem niniejszego opracowania jest omówienie koncepcji ELT oraz jezior danych, przedstawienie ich założeń, różnic w stosunku do klasycznych rozwiązań ETL, a także wskazanie korzyści, ograniczeń oraz obszarów zastosowań w nowoczesnych systemach analitycznych.

2. Klasyczne podejście ETL

Proces ETL stanowi fundament tradycyjnych hurtowni danych. Składa się on z trzech głównych etapów:

- Extract – pobranie danych z systemów źródłowych,
- Transform – oczyszczenie, walidacja, agregacja i dostosowanie danych do docelowego modelu,
- Load – załadowanie przetworzonych danych do hurtowni danych.

Transformacje realizowane są przed załadowaniem danych, zazwyczaj w dedykowanych narzędziach ETL. Dzięki temu dane trafiają do hurtowni w formie już ustrukturyzowanej, zgodnej z wcześniej zaprojektowanym schematem (np. schemat gwiazdy lub płatka śniegu).

Podejście to zapewnia wysoką jakość danych, spójność oraz kontrolę nad procesami integracji. Jednocześnie wiąże się z pewnymi ograniczeniami:

- długim czasem przygotowania danych,
- wysokim kosztem modyfikacji procesów ETL,
- niską elastycznością w przypadku zmieniających się wymagań analitycznych,

- ograniczoną skalowalnością w kontekście bardzo dużych wolumenów danych.

Powyższe ograniczenia stały się impulsem do rozwoju alternatywnych podejść, takich jak ELT.

3. Koncepcja ELT (Extract, Load, Transform)

ELT (Extract, Load, Transform) jest wariantem klasycznego podejścia ETL, w którym kolejność etapów zostaje zmieniona. Dane pochodzące z systemów źródłowych są:

1. pobierane (Extract),
2. ładowane bezpośrednio do systemu docelowego (Load),
3. przetwarzane i transformowane już w miejscu docelowym (Transform).

Kluczową cechą ELT jest fakt, że transformacje danych realizowane są przy wykorzystaniu mocy obliczeniowej docelowego systemu, którym najczęściej jest hurtownia danych nowej generacji lub platforma chmurowa.

4. Różnice pomiędzy ETL a ELT

Podstawowa różnica pomiędzy ETL i ELT dotyczy momentu wykonywania transformacji. W ETL dane są przetwarzane przed załadowaniem, natomiast w ELT – po załadowaniu. Ma to istotne konsekwencje architektoniczne i organizacyjne.

ELT umożliwia:

- szybsze ładowanie danych,
- przechowywanie danych w postaci surowej,
- wielokrotne wykonywanie różnych transformacji na tych samych danych,
- lepsze wykorzystanie skalowalności nowoczesnych baz danych.

Z drugiej strony, ELT przenosi większą odpowiedzialność za jakość danych na etap analizy oraz wymaga bardziej zaawansowanych kompetencji w zakresie SQL i optymalizacji zapytań.

5. Jeziora danych (Data Lakes)

Jezioro danych (Data Lake) to repozytorium przeznaczone do przechowywania dużych ilości danych w ich pierwotnej, surowej postaci. W przeciwieństwie do hurtowni danych, jeziora danych

nie narzucają sztywnego schematu na etapie zapisu danych (schema-on-read zamiast schema-on-write).

W jeziorach danych mogą być przechowywane:

- dane strukturalne (np. tabele relacyjne),
- dane półstrukturalne (JSON, XML),
- dane niestructuralne (pliki tekstowe, obrazy, logi).

Typowa architektura jeziora danych składa się z kilku warstw:

- warstwy surowej (raw zone) – dane w postaci nieprzetworzonej,
- warstwy przetworzonej (processed / refined zone) – dane oczyszczone i wzbogacone,
- warstwy analitycznej (curated / analytics zone) – dane przygotowane do konkretnych analiz.

Takie podejście pozwala na zachowanie pełnej historii danych oraz elastyczne dostosowanie ich struktury do bieżących potrzeb analitycznych.

6. Relacja pomiędzy ELT a jeziorami danych

ELT oraz jeziora danych są ze sobą ściśle powiązane koncepcyjnie. Jezioro danych bardzo często pełni rolę miejsca docelowego w procesach ELT. Dane są ładowane do jeziora w postaci surowej, a następnie transformowane w zależności od potrzeb analitycznych.

Takie podejście oferuje liczne korzyści:

- możliwość przechowywania surowych danych „na przyszłość”,
- brak konieczności definiowania wszystkich transformacji na etapie projektowania,
- wsparcie dla zaawansowanych analiz, takich jak data science czy machine learning.

Jednocześnie wymaga ono odpowiednich mechanizmów zarządzania metadanymi, kontroli jakości danych oraz bezpieczeństwa.

7. Zalety i wady podejścia ELT i Data Lake

Do najważniejszych zalet ELT i jezior danych należą:

- wysoka skalowalność,
- elastyczność modelowania danych,
- możliwość analizy danych niestrukturalnych,
- skrócenie czasu dostarczania danych do analizy,
- lepsze wykorzystanie nowoczesnych technologii chmurowych.

Mimo licznych zalet, podejścia te wiążą się również z potencjalnymi problemami:

- ryzyko powstania tzw. „data swamp” (nieuporządkowanego jeziora danych),
- większe wymagania kompetencyjne wobec zespołów analitycznych,
- trudniejsza kontrola jakości danych,
- konieczność wdrożenia dodatkowych narzędzi do zarządzania danymi.

W architekturach opartych na ELT oraz jeziorach danych szczególnego znaczenia nabierają zagadnienia związane z zarządzaniem danymi (data governance), metadanymi oraz bezpieczeństwem informacji. W przeciwieństwie do klasycznych hurtowni danych, gdzie struktura i jakość danych są ściśle kontrolowane już na etapie ładowania, w podejściu ELT dane często trafiają do systemu docelowego w postaci surowej.

Brak odpowiednich mechanizmów zarządzania może prowadzić do powstania tzw. *data swamp*, czyli nieuporządkowanego jeziora danych, w którym dane są trudne do odnalezienia, interpretacji i wykorzystania analitycznego. Aby temu zapobiec, konieczne jest stosowanie narzędzi do katalogowania danych, zarządzania metadanymi oraz dokumentowania pochodzenia danych (*data lineage*).

Istotnym aspektem jest również bezpieczeństwo danych. Jeziora danych często przechowują informacje wrażliwe, takie jak dane osobowe, finansowe czy handlowe. W związku z tym niezbędne jest wdrożenie mechanizmów:

- kontroli dostępu na poziomie użytkowników i ról,
- szyfrowania danych w spoczynku i w trakcie przesyłania,
- maskowania danych wrażliwych.

W praktyce zarządzanie danymi w architekturach ELT i Data Lake wymaga ścisłej współpracy zespołów technicznych, analitycznych oraz biznesowych.

8. Hurtownia danych, a jezioro danych – porównanie podejść

Hurtownie danych oraz jeziora danych pełnią różne role w architekturze analitycznej organizacji, mimo że często współlistnieją w jednym środowisku. Hurtownia danych opiera się na zasadzie *schema-on-write*, co oznacza, że struktura danych musi zostać zdefiniowana przed ich załadowaniem. Zapewnia to wysoką jakość i spójność danych, ale jednocześnie ogranicza elastyczność.

Jezioro danych stosuje podejście *schema-on-read*, w którym struktura danych nadawana jest dopiero na etapie analizy. Dzięki temu możliwe jest przechowywanie różnorodnych danych, także takich, które nie mają jednoznacznego zastosowania w momencie ich pozyskania.

W praktyce:

- hurtownie danych są wykorzystywane głównie do raportowania operacyjnego i zarządczego,
- jeziora danych stanowią zaplecze dla analiz eksploracyjnych, data science oraz uczenia maszynowego.

Coraz częściej spotyka się architektury hybrydowe, w których jezioro danych pełni rolę warstwy pośredniej, a hurtownia danych jest zasilana już przetworzonymi i wyselekcjonowanymi danymi.

9. Zastosowania praktyczne

ELT i jeziora danych znajdują zastosowanie przede wszystkim w:

- analizie dużych wolumenów danych,
- projektach Big Data,
- rozwiązaniach opartych na chmurze,
- analityce predykcyjnej i uczeniu maszynowym,
- integracji danych z wielu heterogenicznych źródeł.

W praktyce coraz częściej spotyka się architektury hybrydowe, łączące klasyczne hurtownie danych z jeziorami danych oraz procesami ELT.

10. Podsumowanie

ELT oraz jeziora danych stanowią odpowiedź na rosnące wymagania współczesnych systemów analitycznych. W porównaniu do tradycyjnego podejścia ETL oferują większą elastyczność, skalowalność oraz możliwość pracy z różnorodnymi typami danych. Jednocześnie wymagają świadomego podejścia do zarządzania danymi, jakości informacji oraz architektury systemu.

Wybór pomiędzy ETL, ELT oraz wykorzystaniem jeziora danych powinien być uzależniony od specyfiki organizacji, rodzaju przetwarzanych danych oraz celów analitycznych. W wielu przypadkach najlepszym rozwiązaniem okazuje się połączenie różnych podejść w ramach jednej, spójnej architektury danych.

Literatura

- Chodkowska-Gyurics, A.
Hurtownie danych. Teoria i praktyka.
Wydawnictwo naukowe PWN, Warszawa 2014
- Serra, J.
Nowoczesne architektury danych.
Helion S. A., Gliwice 2025.
- Gorelik, A.
Korporacyjne jezioro danych. Wykorzystaj potencjał big data w swojej organizacji.
Helion S.A, Gliwice 2019

2. Cel realizacji projektu

Celem realizacji projektu jest zapoznanie się ze strukturą danych, ocena ich jakości oraz zaprojektowanie i implementacja pięciu procesów ETL, które zaprezentują możliwie szeroki zakres funkcjonalności programu SAS Data Integration Studio oraz ułatwią analizę danych zawartych w bazie AdventureWorks.

W ramach projektu szczególny nacisk położono na analizę jakości danych w kontekście:

- Integracji danych pochodzących ze źródła zewnętrznego, ich porównanie z danymi systemu wewnętrznego oraz poprawę jakości informacji przy wykorzystaniu mechanizmów walidacji danych i algorytmów podobieństwa tekstowego,
- Utworzenia schematu gwiazdy, który pozwala na przeprowadzenie szerokiego zakresu analiz sprzedażowych, w tym analizę wpływu zastosowanych promocji na wyniki sprzedaży.

Dodatkowo zaprezentowano proces umożliwiający analizę kosztów poszczególnych metod dostaw, a także ilości oraz kosztów produktów nienadających się do dalszego wykorzystania lub sprzedaży. Projekt obejmuje również proces pozwalający analizować terminowość realizacji dostaw sprzedanych produktów.

W ramach projektu nie przeprowadzano testów wydajnościowych, jednak już na etapie projektowania procesów ETL uwzględniono podstawowe zasady wpływające na wydajność przetwarzania w środowisku SAS Data Integration Studio.

3. Opis źródeł danych

Głównym źródłem danych wykorzystanych w projekcie jest baza AdventureWorks, udostępniona przez firmę Microsoft w celach dydaktycznych. Baza ta zawiera 69 tabel, które zostały podzielone zgodnie z logiką biznesową na sześć głównych obszarów:

- | | |
|---------------------|-------------------------|
| • Sales | • Purchasing |
| • Production | • HumanResources |
| • Person | • dbo |

Dane odzwierciedlają działalność przedsiębiorstwa zajmującego się produkcją i sprzedażą rowerów i akcesoriów w okresie od 01 lipca 2001 do 31 lipca 2004, obejmując m.in. informacje o sprzedaży, klientach, produktach, procesach produkcyjnych, logistyce oraz zakupach.

Struktura wybranych tabel

Ze względu na dużą liczbę tabel oraz kolumn występujących w bazie źródłowej AdventureWorks, dalszy opis został ograniczony do wybranych tabel i koncentruje się na kluczowych atrybutach biznesowych oraz kolumnach wykorzystywanych w procesach ETL.

Struktura tabeli SALES_SALESORDERHEADER

Dane w tabeli opisują sprzedaż na poziomie pojedynczego zamówienia - jedno zamówienie odpowiada jednemu rekordowi w tabeli.

Kluczem głównym tabeli jest **SalesOrderID**. Klucze obce to:

- CustomerID – identyfikator klienta składającego zamówienie,
- ContactID – identyfikator danych kontaktowych powiązanych z zamówieniem,
- SalesPersonID – identyfikator pracownika odpowiedzialnego za realizację sprzedaży,
- TerritoryID – identyfikator obszaru sprzedażowego, do którego przypisane jest zamówienie,
- BillToAddressID – identyfikator adresu rozliczeniowego zamówienia,
- ShipToAddressID – identyfikator adresu dostawy zamówienia,
- ShipMethodID – identyfikator metody wysyłki wykorzystanej do realizacji zamówienia,
- CreditCardID – identyfikator karty płatniczej użytej do opłacenia zamówienia,
- CurrencyRateID – identyfikator kursu waluty zastosowanego przy przeliczeniu wartości zamówienia.

Do kolumn czasowych, które zostały wykorzystane m.in. w procesie analizy opóźnień dostaw, należą:

- OrderDate – data złożenia zamówienia,
- DueDate – planowana data realizacji,
- ShipDate – rzeczywista data wysyłki.

Kolumny czasowe obejmują daty od 01 lipca 2001 do 31 lipca 2004.

Kolumny wartościowe, które opisują strukturę kosztów zamówienia i stanowią podstawę analiz finansowych to:

- SubTotal – łączna wartość pozycji zamówienia przed podatkiem i kosztami dostawy,
- TaxAmt – kwota podatku naliczonego dla zamówienia,
- Freight – koszt dostawy zamówienia,
- TotalDue – całkowita kwota do zapłaty, obejmująca łączną wartość pozycji zamówienia wraz z podatkiem i kosztem dostawy.

Zakres danych został obliczony przy użyciu węzła **Summary Statistics** (Tabela 1).

Nazwa Kolumny	Średnia	Odch. Std.	Minimum	Maksimum	Ilość
SubTotal	4046.95	13563.18	1.37	224356.48	31465
TaxAmt	323.75	1085.05	0.11	17948.52	31465
Freight	101.17	339.079	0.03	5608.91	31465
TotalDue	4471.88	14987.31	1.52	247913.91	31465

Tabela 1 Zakres danych kolumn wartościowych tabeli SALES_SALESORDERHEADER

Pozostałe kolumny mają charakter techniczny lub operacyjny i nie wnoszą istotnej wartości analitycznej w kontekście realizowanych procesów ETL i modelu hurtowni danych. Obejmują m.in. identyfikatory systemowe, pola kontrolne oraz atrybuty prezentacyjne i referencyjne.

Tabela **SALES_SALESORDERHEADER** pełni rolę centralnej tabeli nagłówkowej dla procesu sprzedaży i przechowuje informacje opisujące zamówienie jako całość. Zawiera dane identyfikujące klienta, sposób realizacji i rozliczenia zamówienia, kontekst organizacyjny sprzedaży (sprzedawca, terytorium) oraz powiązania z adresami i metodą dostawy.

Tabela ta stanowi punkt odniesienia dla szczegółowych danych sprzedażowych przechowywanych w tabeli **SALES_SALESORDERDETAIL**. Dzięki temu możliwe jest analizowanie sprzedaży zarówno na poziomie całych zamówień, jak i pojedynczych pozycji produktowych.

Struktura tabeli SALES_SALESORDERDETAIL

Tabela **SALES_SALESORDERDETAIL** przechowuje dane sprzedażowe na poziomie pojedynczej pozycji zamówienia. Każdy rekord odpowiada konkretnemu produktowi w danym zamówieniu wraz z liczbą zamówionych sztuk (*OrderQty*), co oznacza relację jeden do wielu pomiędzy tabelą **SALES_SALESORDERHEADER** a **SALES_SALESORDERDETAIL**. Kluczem głównym tabeli jest **SalesOrderDetailID**, natomiast kluczem obcym łączącym ją z nagłówkiem zamówienia jest **SalesOrderID**.

Dodatkowe klucze obce umożliwiają powiązanie danych sprzedażowych z innymi obszarami biznesowymi:

- **ProductID** – identyfikator sprzedawanego produktu,
- **SpecialOfferID** – identyfikator zastosowanej promocji.

Tabela zawiera kluczowe miary sprzedażowe wykorzystywane w procesach analitycznych oraz w schemacie gwiazdy:

- **OrderQty** – liczba zamówionych sztuk produktu,
- **UnitPrice** – cena jednostkowa produktu,
- **UnitPriceDiscount** – zastosowany rabat,
- **LineTotal** – łączna wartość pozycji zamówienia.

Zakres danych tabeli obejmuje 121 317 rekordów, co wskazuje, że przeciętne zamówienie składa się z kilku pozycji. Średnia ilość zamówionych produktów w jednej pozycji wynosi około 2,27 sztuki, przy maksymalnej wartości 44 sztuk. Ceny jednostkowe produktów mieszczą się w przedziale od około 1,33 do 3 578,27, natomiast wartości pozycji zamówienia (**LineTotal**) osiągają maksymalnie 27 893,62.

Tabela **SALES_SALESORDERDETAIL** stanowi podstawowe źródło miar sprzedażowych w schemacie gwiazdy i jest kluczowym elementem analiz ilościowych i wartościowych sprzedaży.

Struktura tabeli SALES_SALESSPECIALOFFERPRODUCT

Tabela **SALES_SALESSPECIALOFFERPRODUCT** pełni rolę tabeli asocjacyjnej, łączącej produkty z ofertami specjalnymi. Każdy rekord określa, że dana promocja (*SpecialOfferID*) może być zastosowana do konkretnego produktu (*ProductID*). Tabela ta umożliwia realizację relacji wiele do wielu pomiędzy produktami a ofertami promocyjnymi.

Tabela składa się z następujących kluczowych kolumn:


- SpecialOfferID – identyfikator oferty specjalnej,
- ProductID – identyfikator produktu objętego promocją,
- ModifiedDate – data ostatniej modyfikacji rekordu.

Zakres danych obejmuje 538 rekordów, co oznacza, że tylko wybrane produkty w bazie AdventureWorks objęte są ofertami specjalnymi. Liczba dostępnych ofert specjalnych wynosi 16.

Tabela SALES_SALESSPECIALOFFERPRODUCT nie zawiera miar liczbowych, lecz pełni istotną rolę logicznego powiązania danych, umożliwiając analizę wpływu promocji na sprzedaż produktów. Dane z tej tabeli zostały wykorzystane w procesie budowy wymiaru **SpecialOffer_dim** oraz w analizach sprzedaży z uwzględnieniem rabatów i ofert specjalnych.

4. Ocena jakości danych

Proces oceny jakości danych (Rysunek 1) obejmuje profilowanie danych źródłowych, walidację reguł biznesowych oraz analizę spójności i jednoznaczności danych.




Rysunek 1 Proces ETL - ocena jakości danych

Ocena jakości danych została przeprowadzona na przykładowej tabeli **SALES_CUSTOMER**.

W ramach analizy sprawdzono następujące metryki jakości danych:

- Jednoznaczność klucza
- Kompletność danych
- Poprawność wartości słownikowych
- Poprawność formatu danych

Jednoznaczność klucza




#	wynik	UniqueC
...	UNIKALNE	19185
...	WSZYSTKIE	19185

Rysunek 2 Widok danych - liczba unikalnych wartości CustomerID

Rysunek 3 User Written Code – kod SQL sprawdzający jednoznaczność klucza

Do sprawdzenia jednoznaczności klucza wykorzystano węzeł User Written Code z przedstawioną procedurą SQL (Rysunek 3). Kolumna **CustomerID** spełnia kryterium jednoznaczności – liczba unikalnych wartości jest równa liczbie rekordów w tabeli (Rysunek 2) i wynosi 19185, co potwierdza brak duplikatów klucza głównego.

Kompletność danych



The screenshot shows the 'View Data: User Written (1 row)' window. The table has one row with the following data:


#	Missing
...	0

Rysunek 4 Widok danych - ilość brakujących wartości

Rysunek 5 User Written Code – kod SQL sprawdzający ilość brakujących wartości

Sprawdzenie ilości brakujących danych wykonano za pomocą kodu SQL (Rysunek 5). W analizowanych kolumnach (**CustomerID**, **CustomerType**, **AccountNumber**) nie występują wartości NULL (Rysunek 4).

Poprawność wartości słownikowych



The screenshot shows the 'View Data: User Written (2 rows)' window. The table has two rows with the following data:


#	Different_Customer_Types
...I	
...S	

Rysunek 6 Widok danych – typy klientów

Rysunek 7 User Written Code – kod SQL sprawdzający typy klientów

W celu sprawdzenia unikalnych wartości w kolumnie **CustomerType** wykorzystano kod SQL (Rysunek 7). Wszystkie wartości kolumny **CustomerType** należą do dozwolonego zbioru {S,I} (Store, Individual) (Rysunek 6).

Poprawność formatu danych



#	Account_Number_Length
...	10

Rysunek 8 Widok danych - długość numerów kont

Rysunek 9 User Written Code – kod SQL sprawdzający poprawność numeru konta


Poprawność formatu danych sprawdzono pod kątem długości wartości w kolumnie **AccountNumber**, korzystając z procedury SQL (Rysunek 9). Wszystkie numery kont (**AccountNumber**) składają się z 10 znaków (Rysunek 8), zgodnie z przyjętą regułą biznesową.

Na podstawie powyższego badania można uznać, że dane zawarte w tabeli **SALES_CUSTOMER** charakteryzują się dobrą jakością.

Analogiczne badanie jakości danych może zostać przeprowadzone również dla pozostałych tabel wykorzystywanych w projekcie. W ramach niniejszej pracy analizę ograniczono do wybranej tabeli w celu czytelnej prezentacji procesu oceny jakości danych.


5. Opis procesów ETL

Proces 1 – Schemat gwiazdy



Rysunek 10 Proces ETL - schemat gwiazdy

Celem procesu jest budowa schematu gwiazdy (Rysunek 10) umożliwiającego wielowymiarową analizę sprzedaży. Model składa się z czterech tabel wymiarów: **Customer_dim**, **Product_dim**, **SpecialOffer_dim**, **Time_dim** oraz centralnej tabeli faktów **Sales_fact**. Poniższy diagram przedstawia logiczny schemat gwiazdy, w którym oznaczono klucze główne i obce, natomiast pominięto typy danych oraz szczegóły implementacji, gdyż nie były one istotne z punktu widzenia tematu niniejszej pracy (Rysunek 11).




Rysunek 11 Diagram schematu gwiazdy

Customer_dim

Tabela **Customer_dim** powstała z połączenia 6 tabel źródłowych (Rysunek 12):

- SALES_CUSTOMER
- SALES_STORE
- SALES_CUSTOMERADDRESS
- PERSON_ADDRESS
- PERSON_STATEPROVINCE
- PERSON_COUNTRYREGION




Rysunek 12 Węzeł Join - schemat połączenia tabel tworzących wymiar Customer_dim

Połączenia zrealizowano przy użyciu odpowiednich kluczy obcych, przy czym tabela **SALES_CUSTOMERADDRESS** posłużyła do powiązania klientów z ich adresami.

Kolumny tabeli **Customer_dim** (Rysunek 13):

- **CustomerID** – identyfikator klienta pochodzący z tabeli **SALES_CUSTOMER**; klucz biznesowy umożliwiający jednoznaczną identyfikację klienta w wymiarze.
- **CustomerType** – typ klienta określający, czy klient jest osobą indywidualną (*I*) czy sklepem (*S*); wartość pochodzi z tabeli **SALES_CUSTOMER**.
- **CustomerName** – nazwa klienta; dla klientów typu *Store* pochodzi z tabeli **SALES_STORE**, natomiast dla klientów indywidualnych przyjmuje wartość zastępczą *Individual*.
- **City** – nazwa miasta klienta, pochodząca z tabeli **PERSON_ADDRESS**.
- **StateProvince** – nazwa stanu lub regionu klienta, pobrana z tabeli **PERSON_STATEPROVINCE**.
- **Country** – nazwa kraju klienta, pochodząca z tabeli **PERSON_COUNTRYREGION**.



#	CustomerID	CustomerName	CustomerType	City	StateProvince	Country
1	1	A Bike Store	S	Seattle	Washington	United States
2	2	Progressive Sports	S	Renton	Washington	United States
3	3	Advanced Bike Com...	S	Irving	Texas	United States
4	4	Modular Cycle Syste...	S	Austin	Texas	United States
5	5	Metropolitan Sports	S	Fremont	California	United States
6	6	Aerobic Exercise Co...	S	Camarillo	California	United States
7	7	Associated Bikes	S	Salt Lake	Utah	United States
8	8	Exemplary Cycles	S	Miami	Florida	United States
9	9	Tandem Bicycle Stor...	S	Millington	Tennessee	United States


Rysunek 13 Widok danych - Tabela **Customer_dim**

Kolumny **CustomerID** oraz **CustomerType** zostały bezpośrednio przekazane z tabel źródłowych.

Kolumna **CustomerName** została utworzona przy użyciu funkcji:

`coalesce("StoreName"n, 'Individual')`

Zastosowanie wyrażenia w polu Expression powoduje przypisanie wartości „Individual” klientom detalicznym, dla których po lewostronnym złączeniu z tabelą SALES_STORE nie istnieje nazwa firmy (Rysunek 14).



Rysunek 14 Węzeł Table Loader – definicja wyrażenia Expression dla kolumny CustomerName

Product_dim

Tabela **Product_dim** zawiera informacje opisujące produkty oraz ich klasyfikację (Rysunek 15):

- ProductID – identyfikator produktu pochodzący z tabeli PRODUCTION_PRODUCT; pełni rolę klucza biznesowego w wymiarze produktu.
- ProductName – nazwa produktu pochodząca z tabeli PRODUCTION_PRODUCT;
- CategoryName – nazwa kategorii produktowej, pochodząca z tabeli PRODUCTION_PRODUCTSUBCATEGORY.
- SubCategoryName – nazwa podkategorii produktu, pochodząca z tabeli PRODUCTION_PRODUCTSUBCATEGORY.

View Data: Product_dim

Go to row Go

#	ProductID	ProductName	CategoryName	SubCategoryName
208	327	Down Tube ...	Other	Other
209	342	Flat Washer 6 ...	Other	Other
210	800	Road-550-W Yello...	Bikes	Road Bikes
211	801	Road-550-W Yello...	Bikes	Road Bikes
212	976	Road-350-W Yello...	Bikes	Road Bikes
213	798	Road-550-W Yello...	Bikes	Road Bikes
214	998	Road-750 Black, 4...	Bikes	Road Bikes
215	975	Road-350-W Yello...	Bikes	Road Bikes
216	977	Road-750 Black, 5...	Bikes	Road Bikes
217	999	Road-750 Black, 5...	Bikes	Road Bikes

Rysunek 15 Widok danych - tabela Product_dim

Kolumny **ProductID** oraz **ProductName** zostały przeniesione bezpośrednio z tabeli PRODUCTION_PRODUCT.

Dla kolumn **CategoryName** oraz **SubCategoryName** zastosowano lewostronne złączenie JOIN, a brakujące wartości zostały zastąpione wartością **Other**, co zapewnia spójność danych w wymiarze (Rysunek 16).

Table Loader Properties

General Load Technique Mappings Options Table Options Code Precode and Postcode Status Handling Parameters Notes Extended Attributes

Source table: Join (W1N8ZQD4)

#	Column	Column Description	Type	Length	Informat	Format
...	ProductID	ProductID	Numeric	8	11	11
...	ProductName	Name	Character	1024	\$1024	\$1024
...	CategoryName		Character	1024	\$1024	\$1024
...	SubCategoryName		Character	1024	\$1024	\$1024

Target table: Product_dim (Product_dim)

#	Column	Column Description	Expression
...	ProductID	ProductID	
...	ProductName	Name	
...	CategoryName		coalesce("CategoryName", "Other")
...	SubCategoryName		coalesce("SubCategoryName", "Other")

Rysunek 16 Węzeł Table Loader – definicja wyrażenia Expression dla kolumn CategoryName oraz SubCategoryName

SpecialOffer_dim

Tabela **SpecialOffer_dim** została utworzona bezpośrednio na podstawie tabeli SALES_SPECIALOFFER.

Kolumny tabeli **SpecialOffer_dim** (Rysunek 17):

- SpecialOfferID – unikalny identyfikator oferty specjalnej,

- Description – opis oferty lub promocji,
- DiscountPct – procentowa wartość udzielonego rabatu,
- OfferType – typ oferty (np. sezonowa, ilościowa),
- OfferCategory – kategoria oferty specjalnej.

View Data: SpecialOffer_dim (16 rows)

Go to row Go

#	SpecialOfferID	Description	DiscountPct	OfferType	OfferCategory
1	1	No Discount ...	\$0.00	No Discount ...	No Discount ...
2	2	Volume Discount...	\$0.02	Volume Discoun...	Reseller ..
3	3	Volume Discount...	\$0.05	Volume Discoun...	Reseller ..
4	4	Volume Discount...	\$0.10	Volume Discoun...	Reseller ..
5	5	Volume Discount...	\$0.15	Volume Discoun...	Reseller ..
6	6	Volume Discount...	\$0.20	Volume Discoun...	Reseller ..
7	7	Mountain-100 Cl...	\$0.35	Discontinued Pr. .	Reseller ..
8	8	Sport Helmet Dis...	\$0.10	Seasonal Disco...	Reseller ..
9	9	Road-650 Overst...	\$0.30	Excess Inventor...	Reseller ..
...	10	Mountain Tire Sa...	\$0.50	Excess Inventor...	Customer ...

Rysunek 17 Widok danych - tabela SpecialOffer_dim

Warto zaznaczyć, że kolumna **DiscountPct** pełni rolę atrybutu opisowego wymiaru **SpecialOffer_dim** i określa parametry oferty promocyjnej, natomiast rzeczywisty wpływ rabatu na wartość sprzedaży jest modelowany jako miara w tabeli faktów.

Wymiar **SpecialOffer_dim** umożliwia analizę wpływu promocji i ofert specjalnych na wyniki sprzedaży.

Time_dim


Wymiar czasu **Time_dim** (Rysunek 18) został wygenerowany przy użyciu węzła **User Written Code**, bez bezpośredniego źródła danych transakcyjnych.

View Data: Time_dim								
Go to row Go 								
#	TimeID	Day	DayOfWeek	Week	Month	Quarter	Year	FullDate
1	20000101	1	7	52	1	1	2000	01JAN2000
2	20000102	2	1	52	1	1	2000	02JAN2000
3	20000103	3	2	1	1	1	2000	03JAN2000
4	20000104	4	3	1	1	1	2000	04JAN2000
5	20000105	5	4	1	1	1	2000	05JAN2000
6	20000106	6	5	1	1	1	2000	06JAN2000
7	20000107	7	6	1	1	1	2000	07JAN2000
8	20000108	8	7	1	1	1	2000	08JAN2000
9	20000109	9	1	1	1	1	2000	09JAN2000

Rysunek 18 Widok danych - tabela Time_dim

Kolumny tabeli **Time_dim**:

- TimeID – klucz techniczny wymiaru czasu, jednoznacznie identyfikujący datę,
- Day – numer dnia miesiąca,
- DayOfWeek – numer dnia tygodnia (1 - niedziela, 2 – poniedziałek itd.),
- Week – numer tygodnia w roku,
- Month – numer miesiąca,
- Quarter – numer kwartału,
- Year – rok kalendarzowy,
- FullDate – pełna data kalendarzowa.



Rysunek 19 Węzeł User Written Code – skrypt SAS wypełniający tabelę Time_dim

Sales_fact

Tabela **Sales_fact** (Rysunek 20) stanowi centralną tabelę faktów schematu gwiazdy. Ziarno tabeli faktów zostało zdefiniowane jako jedna pozycja produktu w ramach jednego zamówienia.

The screenshot shows the 'View Data: Sales_fact' window with a table of sales data. The table has 11 columns: #, SalesID, OrderID, ProductID, CustomerID, TimeID, SpecialOfferID, UnitPrice, Quantity, UnitPriceDiscount, and LineTotal. The data is displayed in a grid with 10 rows and 11 columns.

#	SalesID	OrderID	ProductID	CustomerID	TimeID	SpecialOfferID	UnitPrice	Quantity	UnitPriceDiscount	LineTotal
1	1	43659	776	676	010701	1	\$2,024.99	1	0%	\$2,024.99
2	2	43659	777	676	010701	1	\$2,024.99	3	0%	\$6,074.98
3	3	43659	778	676	010701	1	\$2,024.99	1	0%	\$2,024.99
4	4	43659	771	676	010701	1	\$2,039.99	1	0%	\$2,039.99
5	5	43659	772	676	010701	1	\$2,039.99	1	0%	\$2,039.99
6	6	43659	773	676	010701	1	\$2,039.99	2	0%	\$4,079.99
7	7	43659	774	676	010701	1	\$2,039.99	1	0%	\$2,039.99
8	8	43659	714	676	010701	1	\$28.84	3	0%	\$86.52
9	9	43659	716	676	010701	1	\$28.84	1	0%	\$28.84
...	10	43659	709	676	010701	1	\$5.70	6	0%	\$34.20


Rysunek 20 Widok danych - tabela Sales_fact

Kolumny tabeli **Sales_fact**:

- SalesID – identyfikator pozycji sprzedaży (klucz główny), pochodzący z tabeli SALES_SALESORDERDETAIL.
- OrderID – identyfikator zamówienia sprzedaży, umożliwiający powiązanie wielu pozycji z jednym zamówieniem.
- ProductID – identyfikator produktu sprzedanego w danej pozycji zamówienia.

- CustomerID – identyfikator klienta składającego zamówienie.
- TimeID – identyfikator daty zamówienia.
- SpecialOfferID – identyfikator promocji zastosowanej do danej pozycji zamówienia.
- UnitPrice – cena jednostkowa produktu w momencie sprzedaży.
- Quantity – liczba sprzedanych sztuk produktu w danej pozycji zamówienia.
- UnitPriceDiscount – wartość procentowa rabatu zastosowanego do produktu.
- LineTotal – łączna wartość danej pozycji zamówienia po uwzględnieniu ilości i rabatów.

Dane zostały pobrane z tabel **SALES_SALESORDERDETAIL** oraz **SALES_SALESORDERHEADER** połączonych węzłem **JOIN** przy użyciu klucza **SalesOrderID** (Rysunek 21).




Rysunek 21 Węzeł Join – schemat połączenia tabel tworzących tabelę *Sales_fact*

Kolumna **OrderID** została pozostawiona w tabeli faktów jako wymiar zdegenerowany, umożliwiającą identyfikację oraz analizę danych na poziomie pojedynczego zamówienia, bez konieczności tworzenia dodatkowej tabeli wymiaru.

Kolumna **TimeID** została utworzona na podstawie kolumny **OrderDate** zgodnie z poniższą logiką (Rysunek 22):

put(datepart(SALES_SALESORDERHEADER."OrderDate"n), yymmdn6.)



Rysunek 22 Węzeł Join - definicja wyrażenia Expression dla kolumny TimeID


Analiza danych wynikowych

Dzięki zastosowaniu schematu gwiazdy tabela **Sales_fact** zawiera komplementarny zakres danych sprzedażowych na poziomie pojedynczej pozycji zamówienia, powiązany z kluczowymi wymiarami analitycznymi: klientem, produktem, czasem oraz ofertą specjalną. Takie podejście umożliwia elastyczne i wydajne prowadzenie analiz wielowymiarowych.

Struktura tabeli faktów, oparta na miarach ilościowych i wartościowych (*Quantity*, *UnitPrice*, *LineTotal*), pozwala na łatwą agregację danych w różnych przekrojach, bez konieczności wykonywania złożonych złączeń na poziomie źródeł transakcyjnych. Jednocześnie wymiary dostarczają kontekst biznesowy niezbędny do interpretacji wyników analiz.

Schemat gwiazdy zapewnia wysoką czytelność modelu, dobrą wydajność zapytań oraz zgodność z dobrymi praktykami projektowania hurtowni danych. Utworzony model stanowi solidną podstawę do budowy raportów menedżerskich oraz dalszej rozbudowy hurtowni danych.

Proces 2 – Źródła zewnętrzne, walidacja danych



Rysunek 23 Proces ETL - Źródła zewnętrzne, walidacja danych

Celem procesu jest porównanie danych klientów pochodzących z systemu zewnętrznego z danymi systemu wewnętrznego, identyfikacja niespójności w nazwach klientów, obliczenie dystansu Levenshteina oraz korekta błędnych danych tekstowych.


Źródło zewnętrzne danych

Dane zewnętrzne zostały pobrane z systemu SAS, następnie lokalnie przetworzone poprzez celowe wprowadzenie literówek do losowo wybranych nazw klientów (np. zamiana znaków „o-0”, „i-l”) i udostępnione jako usługa sieciowa w postaci pliku JSON dostępnego przez protokół HTTP.


Źródło danych:

https://raw.githubusercontent.com/szymonZ-z/ETL/refs/heads/typo_sales_store_customer_name/sales_store_external.json

W celu pobrania danych wykorzystano węzeł **REST**, który został skonfigurowany tak, aby zapisywał dane w lokalizacji roboczej projektu (Rysunek 25)(Rysunek 24).



Rysunek 25 Węzeł REST - konfiguracja połączenia ze źródłem zewnętrznym



Rysunek 24 Węzeł REST - konfiguracja wejścia i wyjścia

Mapowanie danych JSON do tabeli SAS

Dane w formacie JSON zostały zmapowane na tabelę SAS przy użyciu poniższego kodu SAS w węźle **User Written Code**:

```
filename dane 'D:\Studenci\stud2026s022etl\sales_store_external';

libname custypos json fileref=dane;

LIBNAME stud1 BASE "D:\Studenci\stud2026s022etl";

data stud1.external_customers;

set custypos.root;

run;
```

Działanie kodu umożliwiło zarejestrowanie tabeli **EXTERNAL_CUSTOMERS**, zawierającej dane klientów z celowo wprowadzonymi literówkami w nazwach (Rysunek 26).

View Data: EXTERNAL_CUSTOMERS		
Go to row Go		
#	CustomerID	Name
1	1	A Bike Store
2	2	Progressive Sports
3	3	Advanced Bike Components
4	4	Modular Cycle Systems
5	5	Metropolitan Sports Supply
6	6	Aerobic Exercise Company
7	7	Associated Bikes
8	8	Exemplary Cycles
9	9	Tandem Bicycle Store
...	10	Rural Cycle Emporium

Rysunek 26 Widok danych - tabela EXTERNAL_CUSTOMERS

Symulacja błędnych danych w zamówieniach

View Data: SALES_ORDERS_TYPOS							
Go to row Go							
#	SalesOrderID	StoreName	SubTotal	TaxAmt	Freight	TotalDue	OrderDate
1	43659	Better Bike Shop	\$24,643.94	\$1,971.51	\$616.10	\$27,231.55	01JUL2001:00:...
2	43660	Pedals Warehouse	\$1,553.10	\$124.25	\$38.83	\$1,716.18	01JUL2001:00:...
3	43661	Original Bicycle Supply Company	\$39,422.12	\$3,153.77	\$985.55	\$43,561.44	01JUL2001:00:...
4	43662	Health Spa, Limited	\$34,689.56	\$2,775.16	\$867.24	\$38,331.96	01JUL2001:00:...
5	43663	World Bike Discount Store	\$503.35	\$40.27	\$12.58	\$556.20	01JUL2001:00:...
6	43664	Capable Sales and Service	\$29,312.40	\$2,344.99	\$732.81	\$32,390.20	01JUL2001:00:...
7	43665	Latest Sports Equipment	\$17,199.28	\$1,375.94	\$429.98	\$19,005.21	01JUL2001:00:...
8	43666	Wheel Gallery	\$6,079.68	\$486.37	\$151.99	\$6,718.05	01JUL2001:00:...
9	43667	Yellow Bicycle Company	\$7,326.50	\$586.12	\$183.16	\$8,095.79	01JUL2001:00:...
...	43668	Retail Mall	\$43,272.07	\$3,461.77	\$1,081.80	\$47,815.63	01JUL2001:00:...

Rysunek 27 Widok danych – tabela SALES_ORDERS_TYPOS

W kolejnym kroku utworzono tabelę SALES_ORDERS_TYPOS (Rysunek 27), symulująca zamówienia klientów z błędnymi nazwami sklepów, które wymagają korekty. Tabela została zbudowana poprzez połączenie tabel:

- SALES_SALESORDERHEADER
- EXTERNAL_CUSTOMERS

Połączenie zrealizowano w węźle JOIN przy użyciu klucza CustomerID.


Następnie wybrano część kolumn, aby zapewnić przejrzystość, a jednocześnie pokazać użyteczność metody.

Kolumny tabeli **SALES_ORDERS_TYPOS**:

- SalesOrderID – unikalny identyfikator zamówienia sprzedaży.
- StoreName – nazwa sklepu zawierająca literówki w części danych.
- SubTotal – wartość zamówienia przed doliczeniem podatków i kosztów przesyłki.
- TaxAmt – kwota podatku naliczonego do zamówienia.
- Freight – koszt przesyłki przypisany do zamówienia.
- TotalDue – całkowita wartość zamówienia, uwzględniająca SubTotal, TaxAmt i Freight.
- OrderDate – data złożenia zamówienia.


Walidacja danych i identyfikacja błędów

W dalszej kolejności wybrano wyłącznie kolumnę **StoreName** i usunięto powtarzające się wartości przy użyciu węzła User Written Code (Rysunek 28).




Rysunek 28 Węzeł User Written Code - Kod SQL wybierający unikalne nazwy z kolumny StoreName

W celu identyfikacji błędnych nazw sklepów wykorzystano węzeł **Data Validation** (Rysunek 29).



Rysunek 29 Węzeł Data Validation – konfiguracja reguły walidacji danych

Jako zbiór poprawnych wartości użyto kolumny **Name** z tabeli **SALES_STORE**, zawierającej właściwe nazwy sklepów. Proces walidacji pozwolił na utworzenie osobnej tabeli błędów zawierającej wyłącznie rekordy z niepoprawnymi nazwami (Rysunek 30).




The screenshot shows a window titled "View Data: Error records table". It features a "Go to row" input field and a "Go" button, along with icons for navigation and printing. Below this is a table with two columns: an index column labeled "#" and a data column labeled "StoreName" with a red triangle icon. The table contains 10 rows of data, each representing a store name with a validation error. The last row is truncated with "...".

#	StoreName
1	A Typical Bike Shop
2	Accessories Network
3	Acclaimed Bicycle Company
4	Active Life Toys
5	Advanced Bike Components
6	Aerobic Exercise Company
7	Alpine Ski House
8	Bicycle Accessories and Kits
9	Bicycle Exporters
...	Bicycle Merchandise Warehouse

Rysunek 30 Widok danych - tabela błędów z węzła Data Validation

Obliczenie dystansu Levenshteina i korekta danych

Dla rekordów zawierających błędne nazwy sklepów obliczono dystans Levenshteina w węźle User Written Code (Rysunek 31), porównując błędne nazwy z listą poprawnych nazw z tabeli **SALES_STORE**.



Rysunek 31 User Written Code - kod obliczający dystans Levenshteina

Wyniki zostały zapisane do tymczasowej tabeli **Temp_name_dict** (Rysunek 32), pełniącej rolę słownika mapującego błędną nazwę sklepu na poprawną nazwę sklepu oraz przechowującą informację o dystansie Levenshteina.

View Data: Temp_name_dict			
#	StoreName	CorrectStoreName	LevenshteinDistance
1	A Typical Bike ShOp	... A Typical Bike Shop	.. 1
2	Access0ries Network	... Accessories Network	.. 1
3	Acclaimed Bicycle C0mpany	... Acclaimed Bicycle Company	... 1
4	Active Life Toys	. Active Life Toys	.. 1
5	Advanced Bike C0mponents	... Advanced Bike Components	... 1
6	Aeroblc Exercise Company	... Aerobic Exercise Company	... 1
7	Alpine Ski H0use	.. Alpine Ski House	. 1
8	Bicycle Access0ries and Kits	... Bicycle Accessories and Kits	... 1
9	Bicycle Exp0rters	.. Bicycle Exporters	.. 1
...	Bicycle Merchandise Wareh0use	... Bicycle Merchandise Warehouse	... 1


Rysunek 32 Widok danych - tabela Temp_name_dict

Budowa tabeli wynikowej

Tabela **SALES_ORDERS_TYPOS** została połączona lewostronnie z tabelą **Temp_name_dict** przy użyciu kolumny **StoreName**. Dla rekordów zawierających poprawne nazwy wartości w kolumnach słownikowych przyjmują wartość NULL.

Na tej podstawie utworzono kolumny końcowe (Rysunek 33):

- **FinalStoreName** – wypełniona przy użyciu funkcji **COALESCE**, która wybiera poprawną nazwę, jeśli została znaleziona, lub nazwę pierwotną w przeciwnym przypadku,
- **LevenshteinDistance** – analogicznie uzupełnianą na podstawie danych słownikowych.



Rysunek 33 Węzeł Join - definicja wyrażenia Expression dla kolumn FinalStoreName i LevenshteinDistance

Tabela docelowa

Ostatecznie dane zostały załadowane węzłem **Table Loader** do tabeli **SalesOrder_NoTypos** (Rysunek 34), która zawiera:

- SalesOrderID - identyfikator zamówienia sprzedaży,
- StoreNamePrevious - pierwotna nazwa sklepu,
- StoreName_dict – niepoprawna nazwa sklepu ze słownika,
- CorrectStoreName_dict – poprawiona nazwa sklepu ze słownika,
- FinalStoreName – nazwa sklepu po korekcie,
- LevenshteinDistance - dystans Levenshteina,
- Pozostałe kolumny z danymi sprzedażowymi.

View Data: SalesOrder_NoTypos								
Go to row Go								
#	SalesOrderID	StoreNamePrevious	StoreName_dict	CorrectStoreName_dict	FinalStoreName	LevenshteinDis...	SubT	
1	51131	Westside Plaza	...	.	Westside Plaza	...	0	\$224,...
2	55282	Westside Plaza	...	.	Westside Plaza	...	0	\$206,0
3	46616	Retail Mall	..	.	Retail Mall	...	0	\$187,...
4	46981	Metropolitan Equipm...	Metropolitan Equipm...	Metropolitan Equipment	Metropolitan Equipm...	...	2	\$182,...
5	47395	Outdoor Equipment Stor...	Outdoor Equipment ...	Outdoor Equipment Store	Outdoor Equipment ...	...	1	\$179,...
6	47369	Bicycle Merchandise War...	Bicycle Merchandise ...	Bicycle Merchandise Wareh...	Bicycle Merchandise ...	...	1	\$171,...
7	51858	Perfect Toys	...	.	Perfect Toys	...	0	\$169,...
8	51822	Field Trip St0re	Field Trip St0re	Field Trip Store	Field Trip Store	...	2	\$157,9
9	47355	Eastside Department Sto...		.	Eastside Department...		0	\$156,9
...	44518	Tread Industries	...	.	Tread Industries	...	0	\$153,4

Rysunek 34 Widok danych - tabela SalesOrder_NoTypos

Kolumny związane z nazwami sklepów (**StoreNamePrevious**, **StoreName_dict**, **CorrectStoreName_dict**) pełnią funkcję informacyjną i nie są wymagane do analiz biznesowych. Zostały jednak zachowane w tabeli wynikowej w celu unaocznienia procesu korekty danych oraz umożliwienia analizy i weryfikacji zastosowanych reguł jakościowych. Tabela **SalesOrder_NoTypos** stanowi przykład procesu poprawy jakości danych oraz integracji danych z systemów zewnętrznych.

Analiza danych wynikowych

Analiza danych zapisanych w tabeli **SalesOrder_NoTypos** pokazuje, że zastosowany proces walidacji i korekty nazw klientów był skuteczny. W kolumnie **FinalStoreName** wszystkie rekordy zawierają spójną i poprawną nazwę sklepu, niezależnie od tego, czy pierwotna wartość zawierała literówki, czy była zgodna ze wzorcem referencyjnym.


Wartości dystansu Levenshteina pozwalają ocenić skalę błędów występujących w danych wejściowych. W analizowanym zbiorze dominują niskie wartości dystansu, co wskazuje na drobne literówki, a nie na poważne rozbieżności semantyczne. Potwierdza to zasadność zastosowania algorytmu podobieństwa tekstowego do automatycznej korekty nazw.

Brak tego procesu mógłby skutkować błędnymi analizami sprzedażowymi wynikającymi z niespójności danych opisowych.

Operacje bardziej kosztowne obliczeniowo, czyli walidacja danych tekstowych oraz obliczanie dystansu Levenshteina zostały zastosowane wyłącznie na ograniczonym zbiorze danych (unikalne

nazwy sklepów), a nie na pełnym zbiorze transakcyjnym. Takie podejście minimalizuje koszt obliczeniowy procesu przy zachowaniu jego funkcjonalności.

Proces 3 – Analiza kosztu dostawy



Rysunek 35 Proces ETL - Analiza kosztu dostawy

Proces został zaprojektowany w celu analizy kosztów przesyłek w zamówieniach zakupowych oraz oceny efektywności poszczególnych metod dostawy. Analiza ta może stanowić podstawę do porównań kosztowych oraz potencjalnych negocjacji z przewoźnikami.

Selekcja i przygotowanie danych


Na potrzeby realizacji procesu wykorzystano tabele z obszaru **PURCHASING**, w szczególności:

- **PURCHASING_PURCHASEORDERHEADER**
- **PURCHASING_SHIPMETHOD**

Tabele zostały połączone w węźle **JOIN** przy użyciu klucza **ShipMethodID**, który jednoznacznie identyfikuje metodę dostawy zastosowaną w zamówieniu zakupowym. Po połączeniu tabel wybrano kolumny istotne z punktu widzenia analizy kosztów przesyłek. Dodatkowo dane zostały posortowane malejąco według wartości **Freight**, co umożliwia łatwą identyfikację zamówień generujących najwyższe koszty transportu.

Tabela docelowa

Przygotowane dane zostały załadowane węzłem **Table Loader** do tabeli docelowej **ShippingCostFact** (Rysunek 36), która pełni rolę tabeli faktów dla analiz kosztów przesyłek.



#	PurchaseOrderID	ShipMethodID	OrderDate	SubTotal	Freight	FreightRatio
1	4012	3	25JUL2004:00:...	\$997,680.00	\$19,953.60	0.02
2	4007	3	01APR2004:00:...	\$554,020.00	\$11,080.40	0.02
3	4008	3	23MAY2004:00:...	\$396,729.00	\$7,934.58	0.02
4	335	2	27MAY2003:00:...	\$152,581.28	\$3,814.53	0.0250000002
5	1895	2	08MAR2004:00:...	\$152,581.28	\$3,814.53	0.0250000002
6	2685	2	23MAY2004:00:...	\$152,581.28	\$3,814.53	0.0250000002
7	3475	2	27JUL2004:00:...	\$152,581.28	\$3,814.53	0.0250000002
8	177	2	24JUL2002:00:...	\$101,720.85	\$2,543.02	0.0250000005
9	1737	2	18FEB2004:00:...	\$101,720.85	\$2,543.02	0.0250000005
...	2527	2	09MAY2004:00:...	\$101,720.85	\$2,543.02	0.0250000005

Rysunek 36 Widok danych - tabela ShippingCostFact

Kolumny tabeli **ShippingCostFact**:

- PurchaseOrderID – unikalny identyfikator zamówienia zakupu,
- ShipMethodID – identyfikator metody wysyłki zastosowanej dla zamówienia,
- OrderDate – data złożenia zamówienia zakupu,
- SubTotal – wartość zamówienia przed doliczeniem kosztów wysyłki,
- Freight – koszt transportu,
- FreightRatio – udział kosztu transportu w wartości zamówienia ($\text{Freight} / \text{SubTotal}$)

Kolumny wyliczane

W procesie dodano kolumnę obliczeniową **FreightRatio**, która określa udział kosztu przesyłki w wartości zamówienia. Wskaźnik ten pozwala na porównywanie efektywności różnych metod dostawy niezależnie od wartości zamówienia.

Logika wyznaczania kolumny **FreightRatio** została zrealizowana przy użyciu następującego warunku:

CASE

WHEN PURCHASING_PURCHASEORDERHEADER."SubTotal"n > 0

THEN PURCHASING_PURCHASEORDERHEADER."Freight"n /

PURCHASING_PURCHASEORDERHEADER."SubTotal"n

ELSE 0

END

Analiza danych wynikowych

Tabela **ShippingCostFact** zawiera informacje dotyczące kosztów dostawy zamówień zakupowych, zestawione z wartością zamówienia oraz zastosowaną metodą transportu. Dane prezentowane są na poziomie pojedynczego zamówienia zakupowego (**PurchaseOrderID**), co umożliwia szczegółową analizę relacji pomiędzy wartością zamówienia a kosztem przesyłki.


Na podstawie struktury tabel źródłowych, w szczególności tabeli **PURCHASING_SHIPMETHOD**, w której występują kolumny **ShipBase** oraz **ShipRate**, można wnioskować, że koszt dostawy powinien być obliczany jako suma opłaty bazowej oraz stawki zależnej od wagi przesyłki. Jednak analiza danych wynikowych pokazuje, że rzeczywista wartość kolumny **Freight** nie jest wyliczana w oparciu o te parametry.

W praktyce koszt dostawy stanowi stały procent wartości zamówienia (**SubTotal**) i przyjmuje jedynie dwie wartości: około 2% wartości zamówienia lub około 2,5% wartości zamówienia.

Zależność ta została potwierdzona przez analizę wskaźnika **FreightRatio**, który dla wszystkich rekordów przyjmuje jedną z powyższych wartości.

Oznacza to, że w bazie AdventureWorks kolumny **ShipBase** oraz **ShipRate** pełnią funkcję demonstracyjną, a rzeczywista logika naliczania kosztów przesyłki została uproszczona na potrzeby przykładowej bazy danych.

Proces 4 – Opóźnienia dostaw, klucz zastępczy



Rysunek 37 Proces ETL - Opóźnienia dostaw, klucz zastępczy

Proces ma na celu analizę terminowości realizacji zamówień oraz identyfikację opóźnień w wysyłkach. Dane zasilające tabelę docelową **DeliveryDelayFact** pochodzą wyłącznie z tabeli **SALES_SALESORDERHEADER**, co jest uzasadnione faktem, że informacje o planowanych i rzeczywistych terminach dostawy są dostępne na poziomie nagłówka zamówienia.

Struktura tabeli docelowej DeliveryDelayFact

#	SalesOrderID	OrderDate	DueDate	ShipDate	IsDelayed	DaysOfDelay	Freight
1	43659	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$616.10
2	43660	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$38.83
3	43661	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$985.55
4	43662	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$867.24
5	43663	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$12.58
6	43664	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$732.81
7	43665	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$429.98
8	43666	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$151.99
9	43667	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$183.16
...	43668	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$1,081.80


Rysunek 38 Widok danych - tabela DeliveryDelayFact

Tabela DeliveryDelayFact (Rysunek 38) zawiera następujące kolumny:

- SalesOrderID – identyfikator zamówienia sprzedaży,
- OrderDate – data złożenia zamówienia,
- DueDate – planowana data realizacji zamówienia,

- ShipDate – rzeczywista data dostawy zamówienia,
- IsDelayed – flaga informująca, czy zamówienie zostało dostarczone po planowanym terminie (1 – opóźnione, 0 – terminowe),
- DaysOfDelay – liczba dni opóźnienia dostawy, wyznaczona jako różnica między datą wysyłki a planowaną datą realizacji (wartości ujemne zastępowane są zerem)
- Freight – koszt transportu przypisany do zamówienia.

Logika wyznaczania opóźnień



Rysunek 39 Węzeł Create Table - definicja wyrażenia Expression dla kolumn IsDelayed oraz DaysOfDelay

Kolumna **IsDelayed** została utworzona w węźle *Create Table* (Rysunek 39) i określa, czy zamówienie zostało wysłane po planowanym terminie dostawy. Jej wartość jest wyznaczana na podstawie następującego warunku:

*CASE WHEN datepart(SALES_SALESORDERHEADER."ShipDate") >
datepart(SALES_SALESORDERHEADER."DueDate") THEN 1 ELSE 0 END*

Kolumna **DaysOfDelay** określa liczbę dni opóźnienia dostawy i jest obliczana jako różnica pomiędzy rzeczywistą datą wysyłki a planowaną datą dostawy, przy czym wartości ujemne są zastępowane zerem:

*max(0, datepart(SALES_SALESORDERHEADER."ShipDate") -
datepart(SALES_SALESORDERHEADER."DueDate"))*


Uwagi dotyczące danych źródłowych

W przykładowej bazie danych **AdventureWorks** nie występują zamówienia z opóźnioną wysyłką, w związku z czym wartości kolumn **IsDelayed** oraz **DaysOfDelay** przyjmują wartość 0 dla

wszystkich rekordów. Pomimo tego proces został zaprojektowany w sposób umożliwiający obsługę opóźnień w rzeczywistych danych produkcyjnych.

Dodanie klucza zastępczego (Surrogate Key)


W celu zapewnienia jednoznacznej identyfikacji rekordów w tabeli faktów oraz uniezależnienia modelu od kluczy biznesowych, utworzono na podstawie tabeli **DeliveryDelayFact** dodatkową tabelę **DeliveryDelayFact_Surr_ID** (Rysunek 40), do której została dodana kolumna **surr_ID**, pełniąca rolę klucza zastępczego.



#	surr_ID	SalesOrderID	OrderDate	DueDate	ShipDate	IsDelayed	DaysOffDelay	Freight
1	1	43659	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$616.10
2	2	43660	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$38.83
3	3	43661	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$985.55
4	4	43662	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$867.24
5	5	43663	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$12.58
6	6	43664	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$732.81
7	7	43665	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$429.98
8	8	43666	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$151.99
9	9	43667	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$183.16
...	10	43668	01JUL2001:00:...	13JUL2001:00:...	08JUL2001:00:...	0	0	\$1,081.80

Rysunek 40 Widok danych - tabela *DeliveryDelayFact_Surr_ID*

Kolumna **surr_ID** została wypełniona przy użyciu węzła **Surrogate Key Generator**, który generuje unikalne wartości liczbowe dla każdego rekordu tabeli (Rysunek 41).



Rysunek 41 Węzeł Surrogate Key Generator - konfiguracja klucza zastępczego

Analiza danych wynikowych

Tabela **DeliveryDelayFact_Surr_ID** zawiera informacje dotyczące terminowości realizacji zamówień sprzedażowych. Każdy rekord odpowiada jednemu zamówieniu i opisuje relację pomiędzy datą planowanej dostawy (**DueDate**) a faktyczną datą wysyłki (**ShipDate**). Tabela zawiera również informację o koszcie transportu (**Freight**), która mogłaby być użyteczna jako argument w przypadku negocjacji wysokości reklamacji z firmą transportową.

Na podstawie danych wynikowych można zauważyć, że w analizowanym zbiorze:

- wszystkie przesyłki zostały zrealizowane przed terminem,
- kolumna **IsDelayed** przyjmuje wyłącznie wartość 0,
- wartość **DaysOfDelay** wynosi 0 dla wszystkich rekordów.


Oznacza to, że w bazie AdventureWorks brak jest przypadków opóźnień dostaw, co uniemożliwia analizę negatywnych scenariuszy logistycznych. Jednocześnie należy podkreślić, że struktura

procesu ETL oraz tabela wynikowa są przygotowane na obsługę takich przypadków, gdyby pojawiły się w przyszłych danych źródłowych.

Natomiast zastosowanie klucza zastępczego umożliwia:

- jednoznaczną identyfikację rekordów niezależnie od kluczy biznesowych,
- potencjalne ukrycie identyfikatorów źródłowych (np. **SalesOrderID**),
- większą elastyczność w dalszej rozbudowie modelu analitycznego (np. w przypadku rozszerzenia analizy o opóźnienia przesyłek przychodzących lub integrację danych z innych systemów logistycznych).

Proces 5 – *Uszkodzone detale*



Rysunek 42 Proces ETL - uszkodzone detale

Proces został zaprojektowany w celu analizy ilości oraz udziału procentowego wadliwych elementów w procesie produkcyjnym, z uwzględnieniem przyczyn odrzucenia oraz strat związanych z wadliwą produkcją. Proces umożliwia prowadzenie analiz w ujęciu miesięcznym oraz tygodniowym, co pozwala na identyfikację trendów i obszarów wymagających optymalizacji.

Źródła danych

Na potrzeby realizacji procesu wykorzystano dane z grupy tabel **PRODUCTION**, w szczególności:

- **PRODUCTION_PRODUCT**
- **PRODUCTION_WORKORDER**
- **PRODUCTION_SCRAPREASON**

Tabele zostały połączone w węzle **JOIN** (Rysunek 43) przy użyciu kluczy:

- ProductID (połączenie produktu ze zleceniem produkcyjnym),
- ScrapReasonID (połączenie z przyczyną odrzucenia).

#	Boolean	(	Operand	...	Operand	)
...			PRODUCTION_PRODUCT."ProductID"n	=	PRODUCTION_WORKORDER."ProductID"n	
...	AND		PRODUCTION_WORKORDER."ScrapReasonID"n	=	PRODUCTION_SCRAPREASON."ScrapReasonID"n	

Rysunek 43 Węzeł Join – sposób połączenia tabel tworzących tabelę **ScrapAnalysisFact**

Tabela docelowa

Wynikowe dane zostały załadowane węzłem **Table Loader** do tabeli docelowej **ScrapAnalysisFact** (Rysunek 44), która pełni rolę tabeli faktów dla analiz jakości produkcji.

#	Pr...	Name	P...	Cl...	Wo...	OrderQty	StandardCost	StockedQty	ScrapedQty	ScrapRe...	StartDate	EndDate	ScrapM...	ScrapYear	TotalScr...	ScrapRate
1	518	ML Road S...	M	H	41	98	\$108.99	97	1	7	04JUL2001:00...	20JUL2001:00...	7	2001	108.99	0.0102040816
2	810	HL Mountai...	M	H	69	120	\$53.40	117	3	11	04JUL2001:00...	20JUL2001:00...	7	2001	160.1997	0.025
3	994	LL Bottom ...	L		85	224	\$23.97	220	4	14	04JUL2001:00...	20JUL2001:00...	7	2001	95.8864	0.0178571429
4	328	Mountain E...			91	240	\$0.00	236	4	15	04JUL2001:00...	14JUL2001:00...	7	2001	0	0.0166666667
5	3	BB Ball Bea...			496	40	\$0.00	39	1	16	15JUL2001:00...	25JUL2001:00...	7	2001	0	0.025
6	3	BB Ball Bea...			1026	50	\$0.00	49	1	4	29JUL2001:00...	08AUG2001:0...	8	2001	0	0.02
7	517	LL Road Se...	L		1302	423	\$98.77	411	12	1	04AUG2001:00...	20AUG2001:0...	8	2001	1185.24	0.0283687943
8	733	ML Road Fr...	R	M	1316	72	\$352.14	70	2	3	04AUG2001:00...	14AUG2001:0...	8	2001	704.2788	0.0277777778
9	744	HL Mountai...	M	H	1325	62	\$699.09	61	1	4	04AUG2001:00...	14AUG2001:0...	8	2001	699.0928	0.0161290323
...	945	Front Derail...			1344	1132	\$40.62	1111	21	7	04AUG2001:00...	20AUG2001:0...	8	2001	853.0536	0.0185512367

Rysunek 44 Widok danych - tabela **ScrapAnalysisFact**


Do tabeli **ScrapAnalysisFact** wybrano kolumny istotne z punktu widzenia analizy ilości, wartości oraz przyczyn odrzucenia komponentów na etapie produkcji:

- ProductID – identyfikator produktu,
- WorkOrderID – identyfikator zlecenia produkcyjnego, stanowiący podstawową jednostkę analizy procesu produkcji,
- ScrapReasonID – identyfikator przyczyny odrzucenia komponentów, umożliwiający analizę źródeł wad produkcyjnych,

- StandardCost – koszt jednostkowy produktu,
- OrderQty – liczba zamówionych elementów,
- StockedQty – liczba elementów przyjętych na stan magazynowy jako wyroby pełnowartościowe,
- ScrappedQty – liczba elementów odrzuconych, posiadających wady,
- StartDate – data rozpoczęcia realizacji zlecenia produkcyjnego,
- EndDate – data zakończenia realizacji zlecenia produkcyjnego,
- Name – nazwa przyczyny odrzucenia komponentów, odpowiadająca wartości ScrapReasonID,
- ProductLine – linia produktowa, do której należy dany produkt,
- Class – klasa produktu określająca jego ogólną kategorię jakościową.

Kolumny te pozwalają na analizę zarówno wolumenu produkcji, jak i strat wynikających z wadliwych elementów.

Kolumny wyliczane



Rysunek 45 Węzeł Table Loader - definicja wyrażenia Expression dla kolumn ScrapYear, ScrapMonth, ScrapRate oraz TotalScrapCost

W procesie dodano również kolumny obliczeniowe (Rysunek 45), umożliwiające przeprowadzenie analiz jakościowych i kosztowych:

- TotalScrapCost – całkowite straty z powodu wadliwych elementów:

$$TotalScrapCost = ScrappedQty * StandardCost$$

- ScrapRate – udział procentowy wadliwych elementów w danym zleceniu produkcyjnym:

$$ScrapRate = ScrappedQty / OrderQty$$

- ScrapMonth – miesiąc zakończenia zlecenia produkcyjnego:

$$ScrapMonth = MONTH(EndDate)$$

- ScrapYear – rok zakończenia zlecenia produkcyjnego:

$$ScrapYear = YEAR(EndDate)$$

Kolumny czasowe umożliwiają prowadzenie analiz w ujęciu miesięcznym oraz rocznym.

Analiza danych wynikowych

Na podstawie danych zgromadzonych w tabeli ScrapAnalysisFact możliwa jest ocena skali strat produkcyjnych wynikających z odrzucenia wadliwych komponentów. Wskaźnik **ScrapRate**, zdefiniowany jako stosunek liczby elementów wadliwych do liczby elementów zamówionych, nie przekracza 4%, co sugeruje relatywnie stabilny i kontrolowany proces produkcyjny.

Jednocześnie analiza ujawnia pewne ograniczenia informacyjne źródeł danych. W tabeli wynikowej brakuje jednoznacznej informacji pozwalającej przypisać przyczynę defektu do winy przedsiębiorstwa, kontrahenta lub przewoźnika. Taki podział umożliwiłby rozróżnienie strat własnych od strat możliwych do zreklamowania i odzyskania kosztów. Należy jednak podkreślić, że baza AdventureWorks nie zawiera tego typu atrybutu, a zatem brak ten nie wynika z błędu projektowego, lecz z ograniczeń danych źródłowych.

W tabeli **ScrapAnalysisFact** znalazł się szeroki zestaw kolumn opisujących zarówno kontekst produkcyjny, jak i charakterystykę produktu, m.in.:

- identyfikatory procesu produkcyjnego (*WorkOrderID*, *ScrapReasonID*),
- dane ilościowe (*OrderQty*, *StockedQty*, *ScrappedQty*),
- dane kosztowe (*StandardCost*, *TotalScrapCost*),
- informacje czasowe (*StartDate*, *EndDate*),
- atrybuty produktowe (*ProductLine*, *Class*).

Część atrybutów, takich jak **ProductLine** oraz **Class**, zawiera znaczną liczbę wartości pustych, a ich interpretacja biznesowa nie jest jednoznaczna bez dodatkowej dokumentacji. W związku z tym ich bezpośrednia użyteczność analityczna w obecnym zakresie jest ograniczona.

Z drugiej strony obecność tych kolumn umożliwia rozszerzenie analiz w przyszłości. Pokazuje też elastyczność procesu ETL i świadome przeniesienie pełnego kontekstu danych źródłowych.

6. Przykładowe raporty

Raporty sprzedażowe – schemat gwiazdy

Schemat gwiazdy utworzony w Procesie nr 1 stanowi centralny element analityczny całego rozwiązania. Umożliwia on generowanie raportów sprzedażowych oraz marketingowych w wielu przekrojach analitycznych. Dzięki zastosowaniu wymiaru czasu możliwa jest analiza sprzedaży w ujęciu dziennym, miesięcznym, kwartalnym oraz rocznym, zarówno na poziomie całej organizacji, jak i dla wybranych produktów, klientów czy promocji.

Model pozwala na ocenę wpływu ofert specjalnych na wielkość sprzedaży, liczbę sprzedanych produktów oraz wartość przychodów. Możliwe jest porównanie wyników sprzedażowych zamówień objętych promocją z zamówieniami realizowanymi bez rabatów, co pozwala na ocenę skuteczności poszczególnych kampanii marketingowych.

Schemat gwiazdy umożliwia również identyfikację najlepszych klientów pod względem wartości sprzedaży lub liczby zamówień. Dzięki temu możliwa jest analiza zmian w zachowaniach klientów, takich jak spadek liczby zamówień, obniżenie wartości koszyka zakupowego lub zmiana preferencji produktowych w określonym okresie czasu.

Dodatkowo możliwa jest analiza sprzedaży poszczególnych produktów oraz kategorii produktowych, porównywanie wyników sprzedażowych w czasie oraz identyfikacja trendów sezonowych, takich jak wzrost sprzedaży w określonych miesiącach lub kwartałach.

Raporty jakości danych – źródła zewnętrzne i walidacja danych

Proces integracji danych ze źródła zewnętrznego oraz ich walidacji umożliwia przygotowanie raportów koncentrujących się na jakości danych oraz spójności informacji pomiędzy systemami. Raporty te mogą obejmować porównanie danych pochodzących z systemu zewnętrznego z danymi

wewnętrznego systemu sprzedażowego oraz identyfikację błędów, takich jak literówki w nazwach sklepów.

Tabela słownikowa **Temp_name_dict**, zawierająca błędne i poprawne nazwy sklepów wraz z wyliczoną odległością Levenshteina, może być wykorzystywana jako uniwersalne narzędzie walidacyjne dla wszystkich raportów, w których wykorzystywana jest nazwa sklepu pochodząca z potencjalnie niespójnych źródeł danych.

W tabeli **SalesOrder_NoTypos**, powstałej po korekcie literówek, znajdują się dane dotyczące wartości zamówień, wysokości podatku, kosztów transportu oraz daty złożenia zamówienia. Na jej podstawie możliwe jest przygotowanie raportów pokazujących zmiany sprzedaży w czasie, kontrolę poprawności naliczania podatku lub analizę kosztów dostaw po uprzednim oczyszczeniu danych.

Raporty logistyczne – koszty przesyłek

Na podstawie tabeli **ShippingCostFact**, utworzonej w Procesie 3, możliwe jest przygotowanie raportów dotyczących kosztów transportu ponoszonych przez firmę AdventureWorks. Raporty te mogą prezentować zarówno sumaryczne koszty dostaw, jak i udział kosztu transportu w wartości zamówienia.

Analiza wskaźnika **FreightRatio** pozwala na identyfikację zamówień, dla których koszty przesyłki stanowią relatywnie wysoki udział w wartości zamówienia. Tego typu raporty mogą stanowić podstawę do renegocjacji umów z obecnymi przewoźnikami lub wyboru alternatywnych metod dostawy.

Dodatkowo możliwe jest sprawdzenie, czy w analizowanym okresie firma korzystała z tych samych metod transportu, czy też następowały zmiany w doborze przewoźników.

Raporty jakości logistyki – opóźnienia dostaw

Tabela wynikowa **DeliveryDelayFact_Surr_ID** umożliwia przygotowanie raportów logistycznych dotyczących terminowości realizacji dostaw. Raporty te mogą obejmować liczbę opóźnionych zamówień w danym okresie, a także sumaryczną liczbę dni opóźnień.

Analiza danych pozwala na ocenę jakości procesów logistycznych oraz identyfikację potencjalnych problemów związanych z realizacją dostaw. Informacje te mogą być wykorzystane do usprawnienia procesów wysyłkowych oraz poprawy poziomu obsługi klienta.

Raporty produkcyjne – analiza uszkodzonych detali

Tabela **ScrapAnalysisFact**, utworzona w Procesie 5, umożliwia przygotowanie raportów związanych z jakością produkcji. Na jej podstawie możliwa jest:

- analiza poziomu wadliwych elementów dla poszczególnych produktów,
- identyfikacja najczęstszych przyczyn odrzucenia komponentów,
- ocena kosztów związanych z wadliwą produkcją,
- analiza trendów jakości produktów w ujęciu miesięcznym oraz rocznym.

Raporty te mogą wspierać decyzje dotyczące optymalizacji procesów produkcyjnych, redukcji strat materiałowych oraz poprawy jakości wytwarzanych produktów.

7. Podsumowanie

Projekt został poświęcony kompleksowej analizie, integracji oraz przetwarzaniu danych z wykorzystaniem środowiska SAS Data Integration Studio oraz bazy danych AdventureWorks. Jego głównym celem było nie tylko techniczne zbudowanie procesów ETL, ale również zrozumienie struktury danych, ich jakości, relacji biznesowych, możliwości analitycznych wynikających z odpowiedniego modelowania hurtowni danych, jak również przybliżenie zagadnień związanych z nowoczesnym przetwarzaniem i składowaniem danych.

W części teoretycznej omówiono procesy ETL oraz ELT, wskazując różnice pomiędzy nimi, obszary zastosowań, a także ich zalety i ograniczenia w kontekście hurtowni danych i analiz biznesowych. Przedstawiono również pojęcia jeziora danych oraz *data swamp*, zwracając uwagę na znaczenie odpowiedniego zarządzania danymi, metadanymi i jakością informacji. Zaprezentowane zagadnienia teoretyczne stanowią fundament dla części praktycznej projektu i odzwierciedlają rozwiązania stosowane w rzeczywistych systemach analitycznych.

Część praktyczna projektu obejmowała pełny cykl pracy z danymi: od analizy źródeł danych, przez projektowanie modeli logicznych, budowę procesów ETL, integrację danych zewnętrznych, aż po przygotowanie struktur umożliwiających zaawansowaną analizę danych i raportowanie.

Szczególny nacisk został położony na pokazanie szerokiego zakresu funkcjonalności SAS Data Integration Studio, w tym pracy z klasycznymi danymi transakcyjnymi, danymi produkcyjnymi, logistycznymi oraz danymi pochodzącymi ze źródeł zewnętrznych.

W ramach projektu zidentyfikowano kluczowe obszary biznesowe działalności firmy AdventureWorks, takie jak sprzedaż, produkcja, logistyka, zakupy oraz jakość danych. Na tej podstawie zaprojektowano i zaimplementowano pięć niezależnych procesów ETL, z których każdy realizował odrębny cel analityczny i biznesowy. Procesy te obejmowały budowę schematu gwiazdy dla analiz sprzedaży, analizę opóźnień dostaw, analizę kosztów przesyłek w zakupach, analizę jakości produktów oraz proces poprawy jakości danych z wykorzystaniem integracji danych zewnętrznych i algorytmów walidacyjnych.

Istotnym elementem projektu było stworzenie schematu gwiazdy, który stanowi podstawę modelu analitycznego hurtowni danych. Dzięki zastosowaniu modelu faktów i wymiarów możliwe stało się prowadzenie wielowymiarowych analiz sprzedaży, takich jak analizy czasowe, produktowe, klienckie oraz promocyjne. Model ten umożliwia zarówno agregację danych, jak i ich szczegółową eksplorację na poziomie pojedynczych transakcji i produktów, co tworzy solidne podstawy pod budowę raportów zarządczych oraz systemów Business Intelligence.

Projekt w sposób świadomy łączył klasyczne przetwarzanie danych transakcyjnych z nowoczesnymi elementami inżynierii danych. Klasyczne przetwarzanie obejmowało ekstrakcję danych z relacyjnych systemów źródłowych, ich transformację, integrację i ładowanie do struktur analitycznych, natomiast nowoczesne podejście widoczne było w obszarach takich jak profilowanie danych, walidacja jakości danych, integracja źródeł zewnętrznych, wykorzystanie algorytmu podobieństwa tekstowego (dystansu Levenshteina), generowanie kluczy zastępczych oraz przygotowanie struktur pod dalszą rozbudowę systemu analitycznego.

Szczególne znaczenie w projekcie miały zagadnienia związane z jakością danych, gdyż ma ona bezpośredni wpływ na jakość analiz, raportów oraz decyzji biznesowych. Procesy walidacji, korekty błędów, standaryzacji nazw oraz integracji danych zewnętrznych stanowiły praktyczną demonstrację tego, że nowoczesne systemy analityczne nie ograniczają się wyłącznie do przetwarzania danych, ale obejmują również aktywne zarządzanie ich jakością.

W projekcie zwrócono również uwagę na znaczenie modelowania danych w kontekście analitycznym. Odpowiedni dobór poziomu szczegółowości danych (granularności), właściwe rozdzielenie faktów i wymiarów oraz świadome projektowanie struktur tabel docelowych miały kluczowe znaczenie dla możliwości dalszej analizy danych. Pokazuje to, że procesy ETL nie są jedynie zagadnieniem technicznym, lecz bezpośrednio wpływają na wartość informacyjną całego systemu.